

长沙学院

CHANGSHA UNIVERSITY

本科生毕业论文

论文题目：基于机器学习的列车通信网络

物理层健康状态诊断方法设计

学院：计算机科学与工程学院

专业：物联网工程

学生姓名：唐 循 宗

班级：21 物联 01 学号 B20210305110

校内指导教师：杨军 职称 高级工程师

最终评定成绩：良 好

长沙学院教务处

二〇二五年五月

长沙学院本科生毕业论文

基于机器学习的列车通信网络物理层健康状态
诊断方法设计

学 院： 计算机科学与工程学院

专 业： 物 联 网 工 程

学 号： B20210305110

学 生 姓 名： 唐 循 宗

校内指导教师： 杨军 高级工程师

2025 年 5 月

毕业论文原创性声明

本人郑重声明：所呈交的毕业论文是本人在老师的指导下独立进行研究所取得的科研成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律后果，并承诺因本声明而产生的法律结果由本人承担。

学生签名：唐循宗

日期：2025 年 5 月 23 日

毕业论文版权使用授权书

本毕业论文作者完全了解学校有关保留、使用论文的规定，同意学校保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权长沙学院可以将本论文的全部内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本论文。

本论文属于

1、保密☐，在____年解密后适用本授权书。

2、不保密☐.

(请在以上相应方框内打“√”)

学 生 签 名：唐循宗

日期：2025 年 5 月 23 日

校内指导教师签名：杨军

日期：2025 年 5 月 23 日



摘 要

列车通信网络作为轨道交通系统中至关重要的信息传输通道，其物理层健康状态的稳定性直接关系到列车运行的安全与可靠性。随着列车通信系统规模的扩展与复杂性的提高，传统的人工巡检与规则诊断方法已难以满足对通信链路状态快速、准确、智能识别的需求。针对这一问题，本文以通信物理层波形信号为研究对象，提出了一种基于多维特征融合与机器学习的健康状态诊断方法，实现对“正常状态”“环境干扰”“通信故障”“线缆退化”四类状态的自动识别。

首先，构建通信波形采样系统，采集四类工况下的物理层信号，并通过小波阈值去噪与中值滤波相结合的方式，对原始信号进行预处理，有效提升了信噪比与数据质量。随后，从时域、频域与小波域三个角度提取统计类与能量类特征，形成多维高维特征集，并结合 ANOVA、互信息、递归特征消除与主成分分析等方法对特征进行筛选，构建具有代表性的共识特征子集。

在分类建模阶段，本文分别构建支持向量机与随机森林模型，并通过交叉验证与网格搜索完成参数优化与性能评估。实验结果表明，两种模型在小样本条件下均能实现 90% 以上的分类准确率，其中 RF 模型在稳定性与运行效率方面更具优势。同时，通过混淆矩阵、ROC 曲线与学习曲线等可视化手段对分类效果进行分析，验证了所提出方法的有效性与鲁棒性。

本文所构建的诊断方法具有准确性高、适应性强、工程可实现性好的特点，为列车通信系统的智能监测与故障预警提供了技术支撑，具有良好的应用推广前景。

关键词：列车通信网络；特征选择；机器学习；信号去噪



ABSTRACT

The train communication network, as a critical channel for information transmission in rail transit systems, heavily relies on the stability of its physical layer. Faults or degradations at this layer may directly compromise system reliability and operational safety. With increasing complexity and scale of modern train communication systems, traditional manual inspection and rule-based diagnosis methods are no longer adequate for timely and accurate assessment. To address this challenge, this study proposes a machine learning-based diagnostic method for physical-layer health status identification using Ethernet waveform signals, targeting four typical operating states: normal, electromagnetic interference, communication fault, and cable degradation.

A waveform acquisition setup is established to collect sampled data under each condition. The raw signals are preprocessed using a hybrid noise reduction strategy combining wavelet threshold denoising and median filtering, which significantly enhances the signal-to-noise ratio and data quality. Multi-dimensional features are then extracted from the time domain, frequency domain, and wavelet domain, capturing key statistical and energy-based characteristics. Feature selection techniques including ANOVA F-test, mutual information, recursive feature elimination, and principal component analysis are employed to construct a compact and discriminative consensus feature subset.

Two classification models—Support Vector Machine and Random Forest—are trained and optimized via cross-validation and grid search. Experimental results demonstrate that both models achieve over 90% classification accuracy under small-sample conditions, with the RF model offering slightly better robustness and computational efficiency. Further analysis using confusion matrices, ROC curves, and learning curves validates the effectiveness and generalizability of the proposed approach.

This work provides a complete and scalable diagnostic framework that integrates signal processing, feature engineering, and intelligent classification. It offers a practical solution for real-time monitoring and fault detection in train communication systems and has promising application potential in intelligent transportation infrastructure.

Keywords: train communication network; feature selection; machine learning; signal denoising



目 录

摘 要.....	I
ABSTRACT.....	II
第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 特征提取研究现状	2
1.2.2 模型方法研究现状	3
1.3 论文结构安排.....	4
第 2 章 研究思路和技术路线.....	5
2.1 系统整体架构设计.....	5
2.2 数据采集与样本构成.....	6
2.3 研究思路与技术路线.....	8
2.4 本章小结.....	9
第 3 章 数据处理方法设计.....	10
3.1 信号特点分析与预处理需求.....	10
3.2 基于小波阈值的去噪算法设计.....	11
3.2.1 小波去噪原理与实现细节	11
3.2.2 不同工况下的参数适配策略	12
3.3 去噪效果评估与信噪比分析.....	13
3.4 本章小结.....	15
第 4 章 特征提取和选择方法.....	17
4.1 特征提取概述.....	17
4.2 特征提取流程.....	18
4.3 特征选择方法.....	20
4.4 共识特征集构建与分析.....	26
4.5 本章小结.....	29
第 5 章 分类模型与评估方法设计.....	30
5.1 分类模型概述.....	30
5.1.1 支持向量机	30
5.1.2 随机森林	30
5.1.3 模型组合与对比动因	31
5.2 模型训练与算法分析.....	31



5.2.1 准备工作概述	31
5.2.2 参数设置与优化	32
5.2.3 模型训练与性能监控	33
5.3 模型评估和性能分析	34
5.3.1 评估指标定义	34
5.3.2 模型性能比较分析	34
5.4 降维与过拟合控制	39
5.4.1 降维技术的应用	39
5.4.2 过拟合风险分析与控制措施	40
5.5 模型融合效果分析	41
5.6 本章小结	41
结 论	42
参考文献	44
致 谢	45



第1章 绪论

1.1 研究背景与意义

随着城市轨道交通和高速铁路系统的不断发展，列车通信网络作为列车控制与调度系统中的神经中枢，其安全性与可靠性正变得尤为关键。以太网因其具备高速、低延迟、标准化强等特性，已成为现代列车通信网络的主流物理层承载方式，广泛应用于车辆控制、信号传输、视频监控、乘客信息等系统中。然而，通信网络的底层稳定性高度依赖其物理层的健康状况。一旦出现物理层退化或异常，可能导致链路抖动、数据误码、网络中断，严重时甚至会影响列车运行安全。

在实际运行环境中，列车网络物理层所面临的干扰因素极其复杂，包括电磁环境干扰、线缆老化损耗、接口接触不良、机械振动冲击等。这些因素会使通信信号发生畸变，影响数据传输质量。传统的网络监测手段多集中于上层协议分析，依赖人工经验进行判断，难以实现对物理层健康状态的实时评估与智能诊断。而且这类手段通常只能在故障发生后进行响应，无法实现“事前预警”和“按状态维护”，不利于提升系统的智能化运维能力。

在工业智能运维（AI Ops）理念与智能检测算法不断发展的背景下，如何结合现代信号处理与人工智能技术，对列车网络物理层的通信波形进行深入分析，实现对物理层健康状态的智能感知与精准识别，成为轨道交通系统高可靠性发展的重要研究方向。特别是在通信信号的物理层状态表现出明显的时序差异特征这一前提下，采用如小波变换、样本熵、频谱分析等方式提取信号深层特征，再引入机器学习分类模型进行状态识别，将有望有效实现“环境干扰”“通信故障”“线缆退化”“正常状态”等典型状态的自动判别。

本论文以列车通信网络中的物理层信号为研究对象，构建从信号去噪、特征提取、特征选择到模型训练与状态诊断的全流程技术框架。通过结合多维信号处理方法与支持向量机、随机森林等主流分类模型，力图实现对物理层状态的准确识别与可视化分析。研究中还针对小样本条件下的泛化能力，提出特征筛选与降维优化策略，提升系统的实用性与部署适应性。

本研究不仅具备明显的工程实用价值，可为列车通信网络的智能维护与状态预测提供有效工具；同时也具有一定的理论意义，为智能信号识别方法在工业通信系统中的应用提供了探索范式，推动轨道交通系统向更高的安全性、可靠性与智能化方向发展。



1.2 国内外研究现状

1.2.1 特征提取研究现状

在列车通信网络物理层健康状态的诊断过程中,特征提取是信号分析与状态识别的核心步骤。有效的特征应能够准确地表征通信信号在不同健康状态(如环境干扰、通信故障、线缆退化等)下的时序变化、频谱分布以及复杂的非线性行为。针对这一问题,研究人员从时域分析、频域变换、小波分解、信息熵理论和多尺度分析等多个角度进行了深入研究。

早期特征提取多基于单一时域或频域统计量,如均值、方差、峰值因子、频谱重心等,虽然计算简单,但对复杂干扰信号的识别能力有限。王欢欢等人将改进的双谱分析与时域特征相结合,提出基于 Bhattacharyya 距离优化的双谱积分路径选择方法,显著增强了特征对辐射源信号个体差异的表达能力,识别率提升至 95%以上,验证了频谱高阶统计特征结合时域指标的有效性^[1]。

小波分析因其具有良好的时频局部化能力,逐渐成为特征提取的主流工具。徐玉龙等提出的小波熵特征利用连续小波变换捕捉不同尺度下的能量分布规律,并计算其熵值作为特征,从而实现对辐射源信号的精确指纹刻画,即便在低至 5 dB 的信噪比下,识别率仍优于 80%,显示出小波熵对噪声鲁棒性强的优点^[2]。

在多尺度非线性动态系统中,基于模态分解的特征提取方法也被广泛应用。靳福涛在滚动轴承诊断研究中,引入 CEEMDAN(完备集合经验模态分解),将非平稳信号分解为多个固有模态函数(IMF),并在不同尺度上提取多尺度熵(MSE)作为状态判别依据,有效捕捉了复杂工况下信号的多层次特性^[4]。朱童在采煤机健康评估中进一步结合鲁棒主成分分析与小波特征,实现了从冗余数据中提取关键健康指标的目的^[11]。

近年来,多域融合特征逐渐成为研究热点。袁晔等提出将 I/Q 信号、功率谱、小波谱信息同时提取,并使用卷积神经网络进行横向与纵向融合,结合注意力机制筛选关键时频特征,在多类噪声干扰下准确率仍保持在 97%以上,展示了深度学习结合融合特征提取的巨大潜力^[3]。

此外,研究还尝试融合统计特征与机器学习算法中的特征重要性指标,通过互信息、F 检验、递归特征消除(RFE)、模型重要性排名(如随机森林)等方式,构建高效、精简的特征子集,为后续分类建模提供高质量输入。胡金昊等人在软件缺陷检测中验证了基于随机森林的重要性排名进行特征筛选的有效性,并结合 SVM 提高了模型的泛化能力^[15]。

综上,特征提取技术正从传统的静态统计量向融合时频分析、小波熵、多尺度建模



和深度特征学习方向演化。这些技术为复杂环境下的通信信号识别和健康状态评估提供了强有力的支持，也为本论文设计诊断方法提供了理论基础和技术借鉴。

1.2.2 模型方法研究现状

在列车通信网络物理层健康状态的诊断过程中，分类模型承担着将提取的特征映射为具体健康状态类别的关键任务。近年来，随着统计学习理论、集成学习和深度学习的快速发展，支持向量机（SVM）、随机森林（RF）等模型因其良好的泛化能力和鲁棒性，被广泛应用于通信信号分类、设备故障诊断等领域。

支持向量机作为一种基于结构风险最小化原则的监督学习方法，尤其适合处理高维、小样本、非线性问题。彭璐^[5]对 SVM 的求解方法进行了系统研究，并结合遗传算法对核参数与惩罚系数进行寻优，显著提升了模型在复杂场景中的分类性能。该研究同时强调了参数优化对模型泛化能力的直接影响。郑和忠^[9]将 SVM 与主成分分析（PCA）相结合应用于地震波形分类中，有效缓解了数据维度冗余问题，实现了多类复杂波形的高效分类识别。

在复杂工况和低信噪比环境下，集成学习方法显示出更强的稳定性和抗干扰能力。随机森林作为一种基于决策树集成的非参数方法，具备处理高维数据、自动选择重要特征的能力。万广等人将 RF 用于茶鲜叶图像分类，通过颜色与边缘特征融合提升了模型准确率至 99.45%，且优于 KNN 和 SVM 等对比模型^[8]。在软件缺陷预测任务中，胡金昊^[15]利用 RF 进行特征筛选，并结合 SVM 构建组合模型，在多个真实数据集上均实现了高精度预测，体现了随机森林与 SVM 协同作用在数据预处理和分类建模中的实用性。

此外，许多研究尝试引入参数寻优算法（如粒子群优化、遗传算法、灰狼优化等）进一步提升模型性能。黎梓昕等提出的 KPCA-PSO-SVM 模型，在水轮机组故障检测中显著优于单一模型，识别率高达 96.73%^[12]。董红召等结合 PCA、PSO 和 SVM 建立了臭氧浓度预测模型，融合时空特征后，预测精度提升了 19%，说明融合优化与维度压缩是提高分类和预测精度的有效途径^[13]。

在深度学习方面，虽然其对训练样本数量与计算资源要求较高，但在融合多源信号和复杂模式识别中表现出强大的表达能力。袁晔等构建的 M-ResNeXt 网络，通过时频特征融合和注意力机制处理通信信号，在高噪声条件下识别率依然保持在 97%以上，显示出深度学习在强干扰信道条件下的出色稳健性^[3]。

综合来看，当前通信网络物理层健康诊断模型研究正从传统浅层分类器向“特征选择 + 参数优化 + 模型集成 + 深度结构”的组合式演进。在实际工业场景中，如何在保持高准确率的同时兼顾实时性与可部署性，将是未来模型方法研究的重要方向。



1.3 论文结构安排

第一章 绪论。介绍课题的研究背景与实际意义，综述国内外在通信物理层健康诊断、信号特征提取及分类建模等方面的研究现状，明确本课题的研究目标和技术路线，并概述论文的整体结构。

第二章 系统设计与研究方案。本章围绕健康状态诊断系统的整体设计展开，说明了系统架构构成与功能分层，详细介绍了采集数据的来源与类型，并阐述了本文的研究思路和技术实现路线，为后续章节的实现与分析提供理论基础。同时，构建实际通信信号样本的测试集，通过对比实验验证所提诊断方案的有效性，为模型效果分析提供基础数据支撑。

第三章 数据预处理与去噪方法设计。针对通信物理层信号中存在的高频干扰与背景噪声问题，提出了一种基于小波阈值的自适应去噪方法，并对不同工况下的参数调节策略进行了设计与实验验证。最终，通过信噪比等指标对去噪效果进行评估，并在数据可视化过程中直观展示去噪前后的对比结果，增强对处理效果的理解。

第四章 多维特征提取与选择方法。本章从时域、频域和小波域三个维度构建特征体系，详细介绍了特征提取的具体流程与方法；在此基础上，结合 F 检验、互信息、递归特征消除等多种特征选择手段，构建最优特征子集，并分析其对诊断性能的影响。为进一步提升模型的可解释性，辅以图表形式展示各特征的贡献度与选择过程。

第五章 分类模型设计与性能评估。针对多类健康状态的识别需求，选取支持向量机与随机森林等典型模型进行训练与优化，设计交叉验证和参数调节策略，并使用准确率、混淆矩阵、ROC 曲线等指标对模型性能进行系统评估。结合前文实验数据，进一步分析特征选择对分类效果的影响，探讨降维与过拟合控制方法，并通过可视化手段呈现模型的诊断流程与分类效果。

结论与展望。总结本文的研究成果与主要贡献，分析所提方法的优势与不足，展望未来在迁移学习、轻量化部署、复杂工况识别等方面的进一步研究方向。

第 2 章 研究思路和技术路线

2.1 系统整体架构设计

为了实现对列车通信网络物理层健康状态的智能识别与诊断，本文设计了一套结构清晰、功能完整的状态识别系统。系统整体架构主要包括数据采集模块、信号预处理模块、特征提取与选择模块、分类识别模块和结果输出模块五个核心部分。各模块之间协同工作，构成从通信信号输入到健康状态判断的闭环流程。系统架构如图 2.1 所示。




图 2.1 系统架构流程图

(1) 信号预处理模块。通信信号在实际采集过程中易受到高频噪声、脉冲干扰等因素影响，需先行去除冗余干扰以保证特征提取质量。本模块采用基于小波阈值的自适应去噪方法，对不同工况自动调整小波基与分解层数，同时在高干扰场景下引入中值滤波进行补充优化。预处理后的信号具备更高的信噪比和更清晰的变化结构。

(2) 特征提取与选择模块。本模块从去噪后的信号中提取多维度特征，包括时域统计量、频域频谱特征、小波能量与熵特征等，构建全面反映信号状态的特征向量。随后，采用 F 检验、互信息、递归特征消除 (RFE) 等多种方法进行特征重要性评估，构建最优特征子集，有效降低冗余信息和维度带来的计算负担。

(3) 分类识别模块。该模块使用支持向量机 (SVM)、随机森林 (RF) 等监督学习模



型对输入的特征向量进行训练与预测。模型通过交叉验证选定最优超参数，提升分类准确率与鲁棒性。输入样本最终被自动判别为对应的健康状态标签，实现状态智能识别。

(4) 结果输出与可视化模块。识别结果以标签形式输出，并可通过图形方式展示诊断过程中的信号波形、特征趋势、分类边界等信息，提升模型可解释性。该模块可为列车维护人员提供直观、实时的健康状态反馈，支持后续状态追踪与运维决策。

整体架构设计兼顾模块化、扩展性与工程部署需求，为后续将模型集成到车载监控或地面运维系统中提供了良好基础。

2.2 数据采集与样本构成

本研究面向列车通信网络物理层的典型工况，围绕实际运行中易发生的信号退化情形，设计并构建了具代表性的数据集。采集过程中，模拟物理层的不同工作状态，通过采样装置获取列车通信网络信号的电压波形数据，作为后续诊断系统建模的原始输入。

本研究以列车通信网络接口的物理层信号为采样对象。信号样本来自实验平台中布设的列车通信网络测试环境，通过高速采样装置对列车通信网络传输过程中代表性链路节点进行连续电压监测。为确保信号采集的一致性与代表性，每种状态下均采集多个独立通道和不同时段的数据。

为研究不同健康状态对通信信号的影响，本实验设计并采集了四种典型物理层状态下的信号样本。每类工况的采样时间相同，但环境干扰工况下采集了 8000 个采样点，正常状态、通信故障、线缆退化工况下分别采集 32000 个采样点。采样波形覆盖典型变化趋势及一定的随机扰动。不同状态下信号表现具有明显差异，如波形扰动幅度、频率分布变化、脉冲异常等，为后续特征分析与分类识别提供了基础支撑

对于不同工况，采样信号会有不同的特点，正常状态特点为通信链路稳定，信号无明显干扰或衰减；环境干扰特点为模拟强电磁干扰环境，如工业设备或高压线路周边干扰；通信故障特点为引入端口接触不良、线缆断续等故障条件；线缆退化特点为使用老化或人为损伤的线缆，表现为信号波形失真、幅值衰减等。其中通过采样点复原的波形图如图 2.2 所示。

本研究采样采用了统一的时序结构进行编码，并根据工况差异设定不同的采样率以保证时间窗口内的数据覆盖长度相近。其中，正常状态、通信故障和线缆退化类信号采用 2000 Hz 采样率，环境干扰类信号因波形采样点数较少，采样率设置为 500 Hz，并通过窗口调整方式对齐信号持续时长。每条信号数据均包含数千个采样点，以序列-电压的形式记录。为了后续的特征提取与模型训练，本研究将原始信号数据划分为 80% 的训练集与 20% 测试集，再将每个波形划分为固定 512 采样点长度的无重叠窗口，每个窗口作为一个独立样本，最终形成用于机器学习建模的标准输入样本集。四类状态的样本



数量在构建过程中保持相对平衡,便于模型训练时进行多类分类任务处理。构建了高质量、多状态的通信物理层信号数据集,为后续诊断系统中信号分析、特征提取和模型训练提供了坚实的数据基础。




图 2.2 四种工况下的复原波形图



2.3 研究思路与技术路线

本研究旨在实现对列车通信网络物理层四种典型状态（正常、环境干扰、通信故障、线缆退化）的智能识别，提升物理层异常监测的主动性与准确性。在任务分析过程中，本文面临多个技术挑战，如信号噪声干扰强烈、状态特征差异不显著、样本量有限、高维特征易导致模型过拟合，以及分类模型选择与参数调优复杂等问题，如表 2.1 所示。

表 2.1 技术挑战和解决策略

技术挑战	主要问题	解决策略
信号噪声干扰复杂	波形中存在高频干扰、尖峰等噪声，影响后续特征提取与分类准确性	采用合适的去噪方法进行多层次去噪处理
多状态特征差异微弱	正常状态与故障状态波形相似，判别边界模糊	结合多域特征提取，增强状态表征能力
数据样本有限	容易导致特征提取受限，不同训练子集的结果差异大	使用迁移学习微调；简化模型同时结合其他模型
特征维度高	高维特征空间易引发“维数灾难”	使用多种特征筛选方法，降低维度避免过拟合
模型选择与参数优化难度大	不同模型表现差异大，参数敏感性强	采用合适的模型，结合其他方法帮助参数优化

因此，研究总体思路采用“问题导向 + 分阶段建模”的策略，从数据质量保障、特征有效表达达到模型构建与性能评估，构建一条自底向上的物理层健康状态诊断路径。研究以采样波形数据为起点，逐步实现信号预处理、特征工程与分类识别，构建一套具备可行性与泛化性的多阶段诊断体系。

为系统推进研究目标，本文设计了技术路线：第一步是数据准备与初步观察。通过对每类状态下采集的原始通信波形数据（32000 个采样点）进行复原与可视化，观察其时序波形形态与异常表现，为特征提取提供感性认知与先验分析依据。第二步是信号去噪与处理。针对通信波形中广泛存在的高频噪声与突变扰动，本文采用多尺度小波阈值去噪与中值滤波相结合的方法，设计了自适应去噪方案。该步骤在保留波形关键结构的同时，有效压制多源干扰，为特征计算提供高质量信号基础。第三步是多域特征提取与标准化。从时域、频域与小波域三个角度提取具有代表性的统计特征（如均值、方差、谱熵、主频等），构建原始高维特征向量。考虑不同特征单位与量纲不一致，进一步通过标准化统一特征尺度，提升模型收敛效率与稳定性。第四步是特征选择与降维优化

为应对“维度灾难”与小样本问题，采用 F 检验、互信息法、递归特征消除（RFE）等特征筛选方法，从多个角度评估特征重要性，去除冗余与弱相关特征，构建更具判别力的低维特征子集，避免过拟合问题。第五步是分类模型构建与评估验证综合支持向量机（SVM）与随机森林（RF）两类具有代表性的分类模型，构建状态识别器。采用交叉验



证与网格搜索对模型超参数进行调优，增强模型对非线性边界与样本不平衡的适应性。最终，通过准确率、召回率、F1 值、混淆矩阵等多指标对模型性能进行系统评估，验证诊断系统的有效性与稳定性。

本技术路线充分考虑列车通信信号的复杂性与工况多样性，构建了以多域特征提取与模型优化为核心的健康状态识别框架。该方法强调数据驱动下的特征分析与模型泛化能力，具有良好的可解释性、工程实用性和拓展性，为实现通信网络物理层的在线监测与智能诊断提供了可行解决方案。

2.4 本章小结

本章围绕列车通信网络物理层健康状态诊断系统的整体设计方案，明确了研究的技术背景与问题挑战，提出了系统化的分层架构与诊断流程。首先介绍了系统的功能组成与模块划分，包括数据采集、信号预处理、特征工程、分类识别与结果输出等关键环节，构建了从原始波形到智能识别的完整流程。随后，详细说明了数据采集方式与样本构成，确保实验基础具备代表性与可操作性。最后，针对诊断任务的核心难点，制定了分阶段的技术路线，从数据质量提升、特征维度优化到模型构建与评估，为后续章节的具体方法实现与实验验证奠定了基础。下一章将重点介绍通信信号的预处理方法，着重解决原始波形中的噪声干扰与异常扰动问题，提升信号分析的可用性与特征提取的稳定性。



第3章 数据处理方法设计

3.1 信号特点分析与预处理需求

在列车通信网络物理层中，列车通信网络信号的波形作为物理层健康状态的关键表征，其时序特性直接反映了通信链路的运行状态与潜在异常。因此，深入理解采集波形的信号特性，并结合诊断目标分析其预处理需求，是后续去噪、特征提取与模型识别的基础。

通过对四种工况（正常状态、环境干扰、通信故障、线缆退化）下的通信波形进行观察与复原，发现通信物理层信号在结构上具有几个显著特征。分别为（1）时序连续性强：通信波形通常表现为连续变化的类周期信号，具备一定的稳定结构，具有良好的时间可追踪性；（2）噪声干扰复杂：特别在“环境干扰”与“通信故障”状态下，信号中存在大量高频干扰、随机脉冲和波形畸变，极大干扰特征提取；（3）状态间差异微弱：正常状态与部分故障状态（如线缆退化）在波形幅值、频谱形态等方面差异不明显，容易混淆；（4）幅值动态范围广：在不同工况下信号振幅可能存在较大变化，不利于模型在原始尺度上有效学习；（5）非平稳性强：受设备抖动、电磁噪声等因素影响，通信波形常具有非平稳性，短时变化剧烈，需采用多尺度分析工具处理。

基于上述信号特点，为了保障特征提取的有效性与诊断模型的鲁棒性，预处理阶段需解决针对核心问题，应对的策略分别为（1）去除高频噪声与干扰脉冲：提高信噪比，保留信号主体结构，避免噪声掩盖关键状态特征；（2）增强信号的平滑性与稳定性：对强突变段进行柔化处理，减缓波形剧烈跳变对统计特征的干扰；（3）保持边缘与能量特征：在去噪过程中避免滤波器“过平滑”导致特征损失，尤其要保留故障相关的短时能量突变；（4）统一数据格式与时间尺度：对不同采样率的波形进行时间对齐与尺度归一，确保后续特征提取在相同分析窗口下进行；（5）兼容后续小波分析与多域处理：预处理结果应满足小波分解等时频分析方法对信号光滑性与长度的要求。

基于上述预处理需求，本文采用“小波阈值去噪 + 中值滤波补偿”的双重策略构建预处理流程。小波去噪可在多尺度上分离信号与噪声，尤其适用于非平稳信号处理；中值滤波则对脉冲干扰具有良好的抑制能力，能够有效清除瞬时异常值。通过两者协同作用，提升了信号质量，为后续的特征提取与建模提供了可靠输入基础。



3.2 基于小波阈值的去噪算法设计

3.2.1 小波去噪原理与实现细节

一、小波去噪原理概述

小波变换是一种兼具时域与频域分析能力的多尺度信号处理方法，特别适用于处理非平稳信号。小波去噪（Wavelet Denoising）通过在不同尺度下分离信号的主要成分与噪声，能够有效保留信号的本质结构并抑制高频干扰。基本思想是将原始信号通过小波变换分解为一组近似系数（低频部分）与若干层细节系数（高频部分），然后对细节系数进行阈值压缩（即将小于设定阈值的系数置零或缩放），最后重构信号。该过程能够去除主要集中在高频域中的噪声成分，同时最大程度保留信号主结构信息。

小波去噪通常包括三个核心步骤。小波分解：选择合适的小波函数与分解层数，对原始信号进行多层小波变换，得到各层细节系数和最终一层近似系数；阈值处理：对细节系数应用软阈值函数（系数压缩后保留其方向性）或硬阈值函数（系数直接置零），将高频噪声削弱或去除；信号重构：使用处理后的系数进行小波逆变换，重建出去噪后的信号。

二、算法实现细节

在本研究中，为处理采集到的列车通信网络信号中存在的大量高频噪声与突变扰动，设计并实现如下小波去噪算法流程：

（1）小波函数选择：综合考虑信号的平滑性与计算效率，选用 Daubechies（db4）小波作为基函数。该函数具有良好的正交性与紧支撑性，适合对通信类电压信号进行边缘检测和局部分析。

（2）分解层数确定：据采样信号长度与主要频率分布，设置小波分解层数为 4 层。该深度在保证低频信号完整保留的同时，能较好分离出高频噪声分量。

（3）阈值函数设计：小波去噪中的关键步骤之一是对高频细节系数进行“阈值处理”，即将噪声主导的细节系数进行抑制。常用的阈值函数包括硬阈值（Hard Thresholding）与软阈值（Soft Thresholding）两种形式：

硬阈值函数定义如下：

$$\hat{d}_i = \begin{cases} d_i, & |d_i| > \lambda \\ 0, & |d_i| \leq \lambda \end{cases} \quad (1.1)$$

式中： d_i ——表示细节系数； λ ——表示阈值。

该方法保留所有大于阈值的系数，直接将小于等于阈值的系数置零。其优点在于对



信号能量保留较完整，但在阈值边界处信号可能出现不连续，易引入伪影（振荡效应）。

软阈值函数定义如下：

$$\hat{d}_i = \begin{cases} \text{sign}(d_i), & |d_i| > \lambda \\ 0, & |d_i| \leq \lambda \end{cases} \quad (2.2)$$

式中： d_i ——表示细节系数； λ ——表示阈值。

软阈值对大于阈值的系数进行平滑压缩，不仅去除了噪声，还抑制了部分高频波动，去噪效果更柔和，能有效降低重构误差。相比硬阈值，软阈值在系数边界处变化更平滑，能有效避免信号重构过程中出现伪影。

（4）阈值自适应设定：阈值大小根据每层细节系数的方差进行自适应计算，引入通用阈值公式：

$$\lambda = \sigma \sqrt{2 \log n} \quad (3.3)$$

式中： σ ——表示噪声估计标准差； n ——表示系数数目。

通过对第一级细节系数中绝对值的中位数估计 σ ，增强算法在不同信号类型下的自适应能力。

（5）边缘效应处理：为避免信号首尾处的边缘截断带来的伪波动，采用“对称延拓”方式填充信号边界，提高重构信号的连续性。

（6）与中值滤波组合优化：考虑到小波去噪对强突变（如尖峰脉冲）处理有限，本文在小波去噪前增加一步中值滤波处理，有效滤除非周期性噪声干扰，进一步提升整体信噪比。

三、结果说明

经多组实际波形处理测试，所设计的多层小波软阈值去噪方法在保留通信波形关键特征的同时，显著降低了高频扰动的影响。与未处理信号相比，去噪后波形轮廓更平滑、波动更稳定，为后续特征提取与状态识别提供了可靠的数据基础。

3.2.2 不同工况下的参数适配策略

列车通信网络物理层信号在不同健康状态下（正常、环境干扰、通信故障、线缆退化）表现出明显的波形差异，如信号幅值变化、频率结构分布、噪声干扰强度等不尽相同。若统一使用固定的小波基与阈值处理，可能导致某些状态下去噪不足或特征丢失。因此，为进一步提升去噪精度与适应性，本文针对不同工况设计了参数自适应的小波去



噪策略。

一、使用参数自适应设计原则

根据工况差异，分别设定小波阈值去噪的小波基函数类型、小波分解层数、细节系数阈值策略三类关键参数。其适配原则如下：（1）信号波动强烈、脉冲干扰频繁时，采用更柔和的小波基（如 db4）与较高分解层数，增强频域分离能力；（2）信号噪声幅度较高时，采用更严格的阈值控制，提升高频压缩效果；（3）正常状态下，注重特征保留，采用较小阈值与较浅分解层数，防止信号主结构失真。

二、不同工况下的参数设定建议如表 3.1 所示。

表 3.1 参数设定建议表

工况类型	小波基函数	分解层数	阈值计算方式	阈值放缩因子 α	中值滤波窗口
正常状态	db4	3	通用阈值： $\lambda = \sigma\sqrt{2\log n}$	0.8	3
通信故障	db4	4	通用阈值（自适应）	1.2	3
线缆退化	sym5	3	局部尺度标准差估计	1.0	3
环境干扰	coif3	5	高放缩通用阈值	1.5	5

参数设定建议表说明：

小波基函数选择：db4 适用于平滑信号去噪，sym5 兼顾对称性，适合微弱退化信号，coif3 支持更多消失矩，适合复杂高频干扰；分解层数：高干扰场景采用较深分解（如 5 层），增强信号与噪声的频域解耦能力；阈值放缩因子：对通用阈值乘以系数 α ，以增强/减弱去噪强度，确保各类信号适配性；中值滤波窗口：在“环境干扰”等强干扰条件下扩大滤波窗口，有效去除孤立脉冲扰动。

三、自适应流程实现

整个去噪模块根据输入信号的标签或波形统计特性（如峰度、能量突变、零交率）判断其所属工况，动态加载相应参数组合。该策略具备三个优势。首先提升了算法对信号非平稳性的适应能力；其次避免“一刀切”阈值造成的特征损失或去噪不足；最后降低了人工调参需求，提高系统自动化程度。

四、实验验证简述

在对比实验中，使用统一参数与自适应参数分别处理四类波形后，发现自适应策略在通信故障与环境干扰等高噪声场景下去噪效果更优，保留了更多故障特征；而在正常状态下，信号重构误差更小，边缘结构保持更完整。

3.3 去噪效果评估与信噪比分析

为了验证所设计的小波阈值去噪方法在不同物理层状态下的有效性，本节对去噪前

后的通信波形进行定量与定性评估。评估指标主要包括信噪比 (Signal-to-Noise Ratio, SNR) 提升量与波形结构保真度, 结合波形可视化与局部细节对比, 综合分析去噪效果对后续特征提取与诊断识别性能的影响。

一、信噪比 (SNR) 定义与计算

信噪比是衡量信号与噪声强弱对比的重要指标, 计算公式如下:

$$SNR = 10 \log_{10} \left(\frac{\sum_{i=1}^N s(i)^2}{\sum_{i=1}^N (s(i) - \hat{s}(i))^2} \right) \quad (4.4)$$

式中: $s(i)$ ——表示原始信号; $\hat{s}(i)$ ——表示去噪后的信号。

其中分母 $\sum_{i=1}^N (s(i) - \hat{s}(i))^2$ 表示信号误差项, 可作为噪声残留能量的近似估计。对于实际采集信号, 可用去噪前波形作为参考基准, 计算去噪后 SNR 的相对提升值。

为提高评估客观性, 本文对四类典型波形分别采样多组窗口数据, 计算其平均 SNR 提升量, 并统计波形平滑度改善程度。

二、去噪效果定量结果




图 3.1 去噪前后 SNR 对比

从图 3.1 中可以看出, 所设计的去噪方法在通信故障、线缆退化、正常状态等况下提升幅度显著, 最大可提升约 12.2 dB, 显著改善信号可用性。同时由于先前根据工况差异, 分别设定了适合工况的小波阈值去噪参数, 所有信号结构保持较好, 避免了特征失真。

三、波形结构保真度评估

为进一步说明信号处理过程中保留了关键特征结构,本文对去噪前后信号进行波形叠加与差值分析。同时绘制去噪前后波形对比图,其中“环境干扰”工况下如图 3.2 所示,结果表明,首先,去噪前后主波段轮廓基本一致,信号主趋势未被削弱;其次异常突变点被有效抑制,短时高频脉冲噪声大幅减少;最后边缘细节结构未被过度平滑,可支持小波熵等敏感特征提取。此外,去噪后信号的峰度指标下降,反映高频突峰数量减少,验证了中值滤波对脉冲干扰的抑制作用。




图 3.2 去噪前后波形图对比

四、对后续任务的影响

在特征提取与分类实验中,去噪处理显著提升了模型的分类准确率,尤其在“环境干扰”与“通信故障”状态下,准确率提升幅度超过 7%。这表明高质量的信号输入不仅提高了特征稳定性,也增强了模型对微弱差异的分辨能力。

3.4 本章小结

本章围绕列车通信网络物理层信号的预处理问题,结合实际采样波形的特点与诊断任务的需求,系统设计并实现了一套基于小波阈值的多层次去噪方法。首先通过信号特性分析,明确了列车通信网络信号在不同工况下所面临的噪声干扰与非平稳性问题;随



后，详细阐述了小波去噪的理论基础与实现流程，选用适配性强的小波基函数，并结合软阈值压缩与中值滤波策略，构建出兼顾去噪强度与特征保留的处理机制。

此外，为提升方法在实际工况下的适应能力，本文根据波形差异性提出了分状态参数适配策略，实现了对不同噪声类型的精细化处理。最后通过信噪比提升量、波形平滑度、结构保真度等指标对去噪效果进行了定量评估，验证了预处理方案在信号质量提升与信息保留方面的有效性。

本章所提出的去噪方法为后续多维特征提取提供了稳定可靠的基础保障，有效增强了模型对信号差异的感知能力，为实现物理层健康状态的准确识别打下了坚实基础。



第 4 章 特征提取和选择方法

4.1 特征提取概述

特征提取是模型训练中不可或缺的一环。由于原始数据常包含噪声（如传感器误差、无关文本符号）或冗余（如重复性统计指标），直接用于模型训练会导致诸如计算开销过大、泛化能力降低、过拟合风险太高等问题，而特征提取的核心意义在于将原始数据转化为更简洁、判别性强、适配模型的特征表示，从而提升分类模型的性能、效率和可解释性。它是连接数据与模型的桥梁，直接影响最终结果的质量。

在物理层健康状态诊断任务中，特征提取是连接原始通信波形与智能分类模型之间的关键桥梁。通过将连续、复杂的原始信号转化为具有判别能力的结构化特征向量，不仅能有效降低数据维度，还能增强模型对不同状态之间微小差异的识别能力。因此，构建科学、全面、鲁棒的特征体系，是提升诊断系统准确性与稳定性的基础。

由于列车通信网络信号在不同工况下可能呈现出非平稳性强、频域变化隐蔽、局部突变特征明显等特点，单一特征维度往往无法充分揭示其内部变化规律。因此，本文采用“多域协同提取”策略，综合利用时域、频域与小波域的统计和能量特征，构建多维、信息丰富的特征表示空间。

表 4.1 三类特征域提取表

特征类型	特征分类	具体特征项
时域特征	统计特征	均值、标准差、最大值、最小值、峰峰值
	波形形状特征	偏度、峭度、波形因子、峰值因子、脉冲因子、裕度因子
	其他时域特征	过零率、过均值率、信号能量、RMS 值（均方根）
	熵特征	样本熵、近似熵、排列熵
频域特征	主频特征	频谱主频及其幅值
	频带能量特征	不同频带的能量占比
	频谱统计特征	频谱重心、频谱标准差、频谱偏度、频谱峭度
时频域特征	功率谱特征	功率谱密度特征、谱熵
	小波特征	小波变换系数统计量、小波能量特征、小波熵

本研究提取的特征如表 4.1 所示。具体而言，时域特征主要反映信号在时间尺度上的基本统计属性和形状特性，如均值、标准差、偏度、峰值因子等；频域特征则揭示信号在频率空间的能量分布和结构特性，如主频、频谱重心、谱熵、频带能量比等；而小波域特征则融合时频信息，能有效表征非平稳信号的局部变异性与多尺度能量变化，如各层小波系数的均值、标准差、能量、熵等指标。



同时，考虑到特征维度较高、部分特征可能存在冗余或弱判别性，后续还将引入特征选择与降维机制，以优化特征子集结构，减少冗余，提高模型泛化能力。本章将围绕特征提取与选择两个层面展开，依次介绍特征的提取流程、计算方法、筛选策略与最终的特征子集构建过程，为后续分类建模提供高质量的输入数据支持。

4.2 特征提取流程

为实现对列车通信网络物理层不同健康状态的准确识别，本文基于预处理后的波形数据，设计了一套系统的多维特征提取流程，覆盖信号的时间、频率及小波尺度三个层面。特征提取流程为信号采样、分段处理、多域计算、特征标准化、向量输出，主要分为信号分段、特征计算与特征整合三大步骤。

一、信号分段与窗口划分

由于原始采样信号数据量较大（每条波形约 32000 个采样点），直接处理完整信号将导致特征提取效率低下，且难以捕捉局部状态变化。为提升计算效率与时序可控性，本文采用固定窗口、无重叠的方式对每条波形进行分段。

窗口长度依据采样率与信号主周期经验选定，确保每段信号包含完整周期信息。对于采样率为 2000 Hz 的波形，窗口长度设定为 512 采样点；对采样率较低的“环境干扰”类信号，适当缩短窗口以保持时长一致性。

二、三类特征域计算方式

分段后，每个信号窗口将作为一个独立样本，分别提取如下时域、频域与小波域特征，特征提取的计算方式及物理意义如表 4.2，4.3，4.4 所示。

表 4.2 时域特征计算表

特征名称	计算公式/说明	物理意义
均值	$\mu = \frac{1}{N} \sum_{i=1}^N x_i$	信号的平均水平，反映直流分量或基线偏移。
标准差	$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$	信号波动强度，值越大表示数据越分散。
最大值	$\max(x_i)$	信号峰值，评估动态范围上限。
最小值	$\min(x_i)$	信号谷值，评估动态范围下限。
峰峰值	$Max - Min$	信号总幅度，用于评估噪声或干扰强度。



偏度	$\frac{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^3}{\sigma^3}$	衡量信号分布不对称性
峭度	$\frac{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^4}{\sigma^4} - 3$	分布尖锐度:高峭度表明存在冲击成分。
波形因子	$\frac{\text{均方根值}}{\frac{1}{N} \sum_{i=1}^N \ x_i\ }$	波形与正弦波的偏离程度,区分平稳与非平稳信号。
峰值因子	$\frac{\text{峰值}}{\text{均方根值}}$	峰值与有效值比率,高值表示瞬态尖峰。
脉冲因子	$\frac{\text{峰值}}{\frac{1}{N} \sum_{i=1}^N \ x_i\ }$	对瞬态冲击敏感,类似峰值因子但更灵敏。
裕度因子	$\frac{\text{峰值}}{(\frac{1}{N} \sum_{i=1}^N \sqrt{\ x_i\ })^2}$	检测早期微弱冲击信号。
过零率	单位时间内信号穿过零点的次数。	反映频率特性。
过均值率	单位时间内信号穿过均值的次数。	类似过零率,消除基线偏移影响。
信号能量	$\sum_{i=1}^N x_i^2$	总能量度量,与信号强度相关。
均方根值	$\sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2}$	平均功率,评估振动烈度或噪声水平。

表 4.3 频域特征计算表

特征名称	计算公式/说明	物理意义
频谱主频及其幅值	傅里叶变换后幅值最大的频率及其幅值。	主要振动频率,识别特征频率。
不同频带能量占比	各频段能量占总能量的比例。	定位能量集中频段,辅助故障类型判断。
频谱重心	$\frac{\sum f_k \cdot A_k}{\sum A_k}$	频谱的“平均频率”,反映能量分布位置。
频谱标准差	$\sqrt{\frac{\sum (f_k - \text{频谱重心})^2 \cdot A_k}{\sum A_k}}$	频谱分布的离散程度,值大表示频带宽。
频谱偏度	$\frac{\sum (f_k - \text{频谱重心})^3 \cdot A_k}{\text{频谱标准差}^3 \cdot \sum A_k}$	频谱不对称性:正偏度表示高频成分多。



频谱峭度	$\frac{\sum (f_k - \text{频谱重心})^4 \cdot A_k}{\text{频谱标准差}^4 \cdot \sum A_k} - 3$	频谱尖锐度:高峭度表明窄带冲击。
功率谱密度	傅里叶变换幅值平方的归一化结果。	功率在频域的分布,分析噪声或共振特性。
谱熵	$H = - \sum p_k \ln p_k (p_k = \frac{A_k}{\sum A_k})$	反映频谱复杂度。

表 4.4 小波域特征计算表

特征名称	计算公式/说明	物理意义
小波系数统计量	从每层小波分解系数提取	多尺度局部特征,适用于非平稳信号分析。
小波能量特征	$E_j = \frac{\sum \ w_j\ ^2}{\sum_{j=1}^J \sum \ w_j\ ^2}$	能量集中频带定位,用于多分辨率诊断。
小波熵	$H = - \sum E_j \ln E_j$	熵值低表示能量集中,熵值高表示能量分散。

各类特征维度经过合理命名与归一化处理,组成统一的特征向量形式,便于后续特征筛选与建模使用。

三、特征标准化与整合

由于不同特征在物理含义、数值范围和量纲上存在较大差异,若直接输入模型,可能造成学习偏差。因此在特征提取后,采用 Z-score 标准化方法对全部特征进行归一化处理,使每个维度的分布均具有均值为 0、标准差为 1 的标准正态形式,增强模型对特征变化的感知能力。最终,每个信号窗口被转化为一个结构化的特征向量,作为分类模型的训练与测试输入。原始数据集也因此转化为标准化的样本特征集,具备良好的扩展性与可读性。

4.3 特征选择方法

特征选择是机器学习中至关重要的步骤,尤其是在高维数据集的分类任务中。通过筛选出最具判别力的特征,我们不仅能够提高模型的计算效率,还能增强模型的预测能力和泛化能力。本研究中采用了四种特征选择方法来选择对列车通信网络物理层健康状况诊断最具影响力的特征。




图 4.1 F 检验分数图




图 4.2 互信息分数图



(1) 单变量特征选择 (Univariate Feature Selection) 方法通过评估每个特征与目标变量之间的相关性, 选择最具判别性的特征。在本研究中, 我们使用了 ANOVA F 检验和互信息作为评估标准。其中 ANOVA F 检验用于计算每个特征与类别之间的方差比值, 较高的 F 值表明该特征对分类任务的贡献更大, F 检验分数如图 4.1 所示。互信息用于衡量特征与目标变量之间的信息共享量, 能够评估特征和目标变量的相关性, 互信息分数如图 4.2 所示。通过计算 F 统计量或互信息分数, 选择得分最高的前 k 个特征。此方法适用于特征数较多时的初步筛选。

(2) 递归特征消除 (Recursive Feature Elimination, RFE) 通过反复训练模型, 并在每次迭代中去除对模型性能影响最小的特征, 最终选出最重要的特征。本研究中, 首先通过交叉验证得到了如图 4.3 所示特征数量和准确率的关系, 再使用 随机森林(RF) 和 支持向量机 (SVM) 两种模型进行特征递归消除。其中随机森林 RFE 通过评估各特征的重要性, 逐步去除重要性较低的特征 (如图 4.4 图 4.5 示)。而 SVM RFE 基于线性 SVM 模型, 去除那些权重较小的特征, 尤其适用于线性关系较强的数据集。RFE 方法能有效处理特征之间的相互关系, 尤其适合于高维数据的特征筛选。




图 4.3 特征数量和准确率的关系图




图 4.4 SVM 消除特征图




图 4.5 RF 消除特征图




图 4.6 SVM 特征重要性




图 4.7 RF 特征重要性

(3) 基于模型的特征重要性 (Model-Based Feature Importance) 通过训练一个分类模型 (随机森林和 SVM), 利用模型内置的特征重要性指标来评估每个特征对分类任务的贡献 (重要性如图 4.6、图 4.5 所示), 其中随机森林特征重要性是通过评估每个特征在树的分裂中对模型精度的影响来衡量特征重要性。SVM 特征重要性: 是通过特征的权重来评估其重要性。此方法可以有效地识别那些对分类有重大影响特征, 适用于复杂模型下的特征选择

(4) 主成分分析 (Principal Component Analysis, PCA) 通过线性变换将原始特征空间投影到新的坐标系中, 以便保留数据集中的大部分变异性。PCA 能够通过降维消除特征之间的相关性, 提取最具信息量的主成分。在特征选择过程中, PCA 可以减少特征的维度, 同时保留最能解释数据变异的特征维度, 其中通过 PCA 贡献得到的主要特征如图 4.8 所示, PCA 方法对于多维度特征的数据集, 能够显著减少冗余, 提高模型的计算效率。




图 4.8 PCA_特征贡献



这四种方法可以单独使用，也可以结合使用，通过比较不同方法的选择结果，进一步优化特征选择的质量。本研究采用了这些方法的结合来选择最优特征集，以提高列车通信网络物理层健康状态分类模型的性能和泛化能力。

4.4 共识特征集构建与分析

在特征选择过程中，不同的特征选择方法可能产生不同的特征子集。在实际应用中，可能无法仅依赖于单一方法来选取最佳特征。因此，共识特征集的构建旨在整合多种特征选择方法的优势，通过计算各特征在不同方法中的出现频率，筛选出那些被多种方法一致选择的特征。这些特征通常具有更高的判别能力，并能有效提高分类模型的稳定性与泛化能力。

一、共识特征集的构建

为确保所选特征在多个方法中的一致性，我们将单变量特征选择、递归特征消除（RFE）、基于模型的特征重要性、主成分分析（PCA）四种特征选择方法的结果进行比较。通过计算每个特征在不同方法中的出现频率，识别出那些在多个方法中均被选中的特征，这些特征即为共识特征。该方法的主要目标是找到所有特征选择方法共同选中的重要特征，从而构建一个有效的特征子集。

二、方法步骤

首先，将不同特征选择方法的输出结果（即每个方法选择的特征）存储在一个列表中。然后，我们使用 Jaccard 相似系数或直接统计重叠特征的数量，衡量每对方法之间的特征重叠程度。其次统计每个特征在所有选择方法中的出现次数。那些在多个方法中被一致选中的特征，将被认为是具有较高判别力的共识特征。最后使用交叉验证评估在共识特征集上的分类性能，比较不同特征选择方法对分类精度的影响。最后基于各特征在多个方法中的表现，我们将构建一个重要性评分，来评价哪些特征对于分类任务最为重要。

三、共识特征集分析

通过对四种特征选择方法的结果进行整合与分析，我们得到以下几方面的结论：第一，共识特征集通常包含那些在大多数特征选择方法中都出现的特征，这些特征在不同方法中有较强的一致性，表明它们对健康状态诊断具有较高的辨识能力。第二，通过使用共识特征集，模型的分类准确率通常会有所提升，尤其是在处理复杂的非线性分类任务时。实验结果表明，基于共识特征集训练的模型，相比于仅使用单一特征选择方法，具有更高的稳定性和更强的泛化能力。第三，共识特征集不仅能够提高分类性能，还能够提高模型的可解释性。通过分析这些特征的物理含义，研究人员可以更清楚地理解不同状态下通信信号的差异。



四、共识特征集与模型性能对比

使用共识特征集训练的分类模型，特别是随机森林和支持向量机模型，在分类任务中的表现更为优越。具体表现为：在使用所有特征时，模型的分类准确率和 F1 分数较高，但计算开销较大。而使用共识特征集时，模型的计算效率大大提高，且分类准确率和精度保持在较高水平。特别是在“环境干扰”和“通信故障”这类信号差异微弱的情况下，共识特征集能够显著提升模型的区分能力。

五、可视化与结果分析

为进一步验证共识特征集的有效性，我们通过以下几个步骤进行可视化分析：

(1) 特征选择方法比较：展示不同特征选择方法的结果，并通过热力图展示各方法之间特征选择的重叠度。如图 4.9 所示




图 4.9 特征选择重叠度



(2) 特征选择频率图：可视化每个特征在不同方法中被选择的频率，识别出被多种方法一致选择的特征。如图 4.10 所示。




图 4.10 特征频率图

模型性能对比：展示使用不同特征选择方法（包括共识特征集）训练的模型在交叉验证中的准确率和 F1 分数的对比结果。如表 4.5 所示。

表 4.5 特征选择方法性能比较

特征集	特征数	RF 识别率	SVN 识别率
所有特征	46	0.865	0.815
ANOVA F 检验	20	0.845	0.86
互信息	20	0.855	0.845
RF 递归特征消除	33	0.87	0.84
SVM 递归特征消除	20	0.895	0.89
RF 特征重要性	20	0.845	0.815
SVM 特征重要性	20	0.905	0.905
PCA 特征贡献	20	0.84	0.79
排名前 20 共识特征	20	0.865	0.865
所有方法共同选择的特征	2	0.6	0.615



最终，通过共识特征集的构建与分析，本研究成功提取出了在多个选择方法中均表现突出的特征，为列车通信网络物理层健康状态的准确诊断提供了更为鲁棒的特征支持。

4.5 本章小结

本章围绕列车通信网络物理层健康状态诊断任务中的特征提取与选择展开，提出了一个基于时域、频域和小波域的多维特征提取框架。通过从不同域中提取具有代表性的统计特征和能量特征，为后续分类模型的训练提供了丰富的特征信息。接着，介绍了四种常用的特征选择方法——单变量特征选择、递归特征消除（RFE）、基于模型的特征重要性以及主成分分析（PCA），并对这些方法进行了详细的评估。

通过分析不同特征选择方法的性能，本研究进一步构建了共识特征集，从中提取出多种特征选择方法共同选中的重要特征，从而提高了特征的判别能力，并减少了冗余信息。实验结果表明，使用共识特征集训练的分类模型在准确率、精度以及计算效率等方面均表现优越。

本章为后续的分类模型设计与训练提供了稳定、高效的特征输入，确保了列车通信网络物理层健康状态诊断系统的高性能与可靠性。同时，特征选择结果在后续分类实验中展现出显著性能差异，进一步验证了所选特征集的合理性。



第 5 章 分类模型与评估方法设计

5.1 分类模型概述

在列车通信网络物理层健康状态的自动诊断任务中，构建有效的分类模型对于提升故障识别的准确率与实时性具有重要意义。考虑到数据量有限、类别间特征差异不显著等问题，本文选用了具有良好泛化能力与鲁棒性的两种主流机器学习模型：支持向量机（Support Vector Machine, SVM）与随机森林（Random Forest, RF）。本节将对这两类模型的基本原理、优缺点及其在本研究中的适用性进行介绍。

5.1.1 支持向量机

SVM 是一种基于统计学习理论的监督式分类算法，其核心思想是通过构造最大间隔的超平面将不同类别的样本尽可能有效地分开。在处理非线性可分问题时，SVM 通过核函数将数据从低维空间映射到高维特征空间，在高维空间中寻找最优分类超平面。

SVM 的核心优势为：（1）高效泛化能力。SVM 采用结构风险最小化原则，能够有效防止过拟合，尤其适合样本量小、特征维度高的任务；（2）可处理非线性分类问题。通过引入核函数（如 RBF 核、线性核等），SVM 能够对非线性可分数据进行有效分类；（3）决策边界明确。分类边界具有良好的几何可解释性。

SVM 的不足之处为：（1）对参数（如惩罚系数 C 、核函数参数 γ ）的设置较为敏感；（2）在多分类问题中通常需要采用“一对一”或“一对多”策略，模型训练复杂度较高；（3）对大规模数据集处理效率不高。

在本研究中，针对小样本、高维数据的波形特征分类任务，本文采用带 RBF 核与线性核的 SVM 模型，并引入交叉验证与网格搜索算法进行参数优化，确保模型既具备较高准确性又能有效控制过拟合。

5.1.2 随机森林

随机森林是一种基于决策树的集成学习算法，通过构建多个决策树并采用投票机制进行分类。其核心机制在于“特征随机选择 + 样本随机采样”的双重随机性，能够有效提升模型的泛化能力。

RF 的核心优势为：（1）鲁棒性强：对缺失值、异常值与噪声不敏感，适合处理实际工程中的复杂数据；（2）特征重要性评估能力强：能自动评估各特征对分类结果的贡献，



有利于特征筛选与结果解释；（3）适合多分类任务：无需额外处理即可自然处理多类别分类问题；（4）训练并行性强：可通过并行方式训练多个树模型，提升运算效率。

RF 的不足之处为：（1）随机性引入可能导致模型结果不稳定；（2）若树的数量或深度设置不当，仍存在过拟合风险；（3）对样本边界的拟合能力不如 SVM 精细。

在本研究中，随机森林不仅作为主要分类器之一，还用于特征重要性评分与特征选择任务，并通过 OOB 误差评估机制及一系列复杂度控制策略（如限制最大深度、最小样本分裂数等）防止模型过拟合。

5.1.3 模型组合与对比动因

SVM 与 RF 各具优势。在高维小样本的非线性分类场景下，SVM 在构造清晰决策边界方面表现出色；而 RF 则在特征冗余、特征选择以及整体鲁棒性方面更为稳健。因此，本研究同时构建两个模型，并尝试在最终阶段引入预测结果的等权集成（模型融合）策略，以提高模型对不确定状态的分类鲁棒性。

通过这种多模型互补设计，本文旨在为列车通信网络的物理层健康状态诊断提供更高效、精准、可靠的分类决策基础。

5.2 模型训练与算法分析

5.2.1 准备工作概述

在构建列车通信网络物理层健康状态分类模型过程中，科学合理的模型训练与参数调优策略直接影响最终分类系统的性能与泛化能力。为确保分类模型在小样本、高维特征空间下具备良好的判别能力，本文结合交叉验证与网格搜索方法，对支持向量机（SVM）与随机森林（RF）两类模型分别进行了系统训练与参数优化。

首先进行数据集划分与标准化处理，为保证模型评估的客观性，本文将预处理后的数据集按 8:2 的比例划分为训练集与测试集，确保各类状态样本在两个子集中分布均衡。此外，为防止特征尺度不一致影响模型学习过程，训练前对所有特征采用 Z-score 标准化处理，使其均值为 0，标准差为 1，从而提升模型收敛速度与分类稳定性。

考虑到数据样本有限，为充分利用现有数据并提升模型泛化能力，本文采用 K 折交叉验证（K=5）对训练过程进行控制。该方法将训练集划分为 5 个子集，轮流作为验证集，其余 4 个子集作为训练集进行模型训练，最终取 5 次评估结果的均值作为该模型的性能指标，有效避免了偶然划分带来的性能偏差。

5.2.2 参数设置与优化

SVM 模型的性能高度依赖于其两个核心参数的设定。惩罚系数 C (控制训练误差与模型复杂度之间的权衡) 和核函数参数 γ (决定样本在高维映射空间中的影响范围)。

因此本研究采用网格搜索 (Grid Search) 策略, 遍历多个候选参数组合, 结合交叉验证结果选出最优超参数配置。每组参数组合都通过 5 折交叉验证评估, 最终选择平均准确率最高的组合作为最佳模型配置, 得到的参数调优结果如图 5.1 所示。




图 5.1 SVM 参数调优结果

随机森林主要依赖于以下几个核心参数: (1) $n_estimators$: 森林中决策树的数量; (2) max_depth : 单棵树的深度; (3) $min_samples_split$: 内部节点再划分所需的最小样本数; (4) $max_features$: 用于寻找最佳划分的最大特征数。

为平衡模型复杂度与性能, 本文同样采用网格搜索方法对 RF 模型进行调参, 每组参数组合均使用 5 折交叉验证评估, 并选取平均准确率最高的一组作为最终配置, 得到的参数调优结果如图 5.2 所示。通过这一策略, 有效控制了模型的过拟合风险, 并提升了训练效率。




图 5.2 RF 参数调优结果

可以得出，在给定的搜索范围内，SVM 模型的最优核心参数为：惩罚系数 $C=10.0$ 、核函数参数 $\gamma=0.1$ ；RF 模型的最优核心参数为： $n_estimators=100$ 、 $max_depth=5$ 、 $min_samples_split=3$ 、 $max_features=2$

5.2.3 模型训练与性能监控

在获取最优超参数后，使用完整的训练集对模型进行最终训练，并监控如下性能指标：

- (1) 学习曲线 (Learning Curve)：观察训练误差与验证误差随样本数量变化的趋势，评估模型是否存在高偏差或高方差问题；
- (2) 训练耗时与预测时间：衡量模型在部署阶段的运行效率；
- (3) 交叉验证误差标准差：反映模型对不同数据划分的鲁棒性。

实验结果表明，经过优化的 SVM 和 RF 模型在训练时间、准确性与稳定性方面均表现良好，具备进一步部署与扩展的基础。



5.3 模型评估和性能分析

为全面评估支持向量机 (SVM) 与随机森林 (RF) 模型在列车通信网络物理层健康状态分类任务中的表现, 本文采用了多种定量指标对模型性能进行测量与分析, 重点从分类准确性、鲁棒性与模型可解释性等角度进行对比, 确保所选模型在工程部署中的可靠性。

5.3.1 评估指标定义

为多维度衡量分类性能, 本文采用如下标准分类评估指标:

- (1) 准确率 (Accuracy): 预测正确样本数占总样本数的比例;
- (2) 精确率 (Precision): 预测为某类的样本中, 真正为该类的比例;
- (3) 召回率 (Recall): 该类样本中被正确识别出来的比例;
- (4) F1 分数 (F1-Score): 精确率和召回率的调和均值, 更适用于不平衡样本场景;
- (5) 混淆矩阵 (Confusion Matrix): 展示模型在各类标签下的分类正确与错误数量;
- (6) 学习曲线 (Learning Curve): 反映模型在不同训练样本数量下的拟合情况与泛化能力。
- (7) AUC (Area Under Curve): ROC 曲线下的面积, 用于评价模型的整体判别能力;

5.3.2 模型性能比较分析

在优化参数后, 对 SVM 与 RF 模型分别使用测试集进行分类测试, 其中准确率、精确率、召回率、F1 分数评估结果如图 5.3 所示。

从图中可以看出: 基于 SVM 和随机森林构建的两种分类模型在四类故障识别任务中均展现出较高准确率, 验证了特征集合具有优异的类别判别能力。从模型对比来看, SVM 虽在准确率与召回率指标上略胜一筹, 但其训练耗时显著增加, 且在区分“线缆退化”与“通信故障”等边界模糊状态时, 因决策边界对微弱差异过于敏感而出现误判; 相较而言, 随机森林通过集成多决策树的优势, 在处理非线性、高维特征时表现出更强的稳健性和泛化能力。从类别识别效果分析, 环境干扰类别的识别准确率最高且混淆最少, 而“线缆退化”的评估效果最为薄弱, 提示需在特征工程中强化对设备退化趋势的动态表征能力, 以提升该类别的敏感度识别。




图 5.3 评估指标图

基于图 5.4 与图 5.5 中 SVM 和随机森林 (RF) 的混淆矩阵分析, 可进一步揭示各类工况的分类细节。结果表明, 环境干扰类别的识别准确率显著优于其他状态, 且与其他类别的混淆程度最低, 突显其特征表征的强区分性。然而, “线缆退化”与“通信故障”在部分样本中仍存在交叉误判现象, 可能与两类状态的特征边界模糊或样本分布不均衡有关, 提示需优化特征提取策略或扩充特定工况的样本规模。尤为突出的是, “线缆退化”状态易被错误归类为“正常”或“通信故障”, 反映现有特征对其渐进性退化趋势的敏感度不足, 未来需在特征工程中强化时序退化指标或引入动态阈值机制, 以提升该类别的辨识鲁棒性。




图 5.4 SVM 混淆矩阵




图 5.5 RF 混淆矩阵




图 5.6 SVM_ROC 曲线图




图 5.7 RF_ROC 曲




图 5.8 SVM 学习曲线




图 5.9 RF 学习曲线



通过结合图 5.6 至图 5.9 中 SVM 与随机森林 (RF) 的 ROC 曲线及学习曲线可视化分析, 可深入对比两类模型的训练动态与分类性能。结果显示, SVM 和 RF 的 AUC 值 (ROC 曲线下面积) 均接近高位水平, 印证了两模型在故障分类任务中具备较高的预测可靠性, 但值得注意的是, “线缆退化” 工况的 AUC 值相对最低, 暗示模型对其渐进性退化特征的捕捉能力仍需强化。从学习曲线来看, SVM 的训练误差与验证误差快速收敛且保持平稳, 表明其泛化能力优异; 而 RF 的训练集得分接近饱和, 测试集表现却显著偏低, 揭示其存在过拟合风险, 需通过调整树深或特征采样策略进一步优化。此外, 通过随机打乱样本多次重训练的稳定性测试表明, RF 模型的性能波动幅度始终小于 $\pm 1\%$, 展现出更强的鲁棒性, 这一特性在复杂工况应用中具有重要价值。

5.4 降维与过拟合控制

在列车通信网络物理层健康状态识别任务中, 采样信号经过多维特征提取后通常会形成高维特征空间。这在提高特征表达能力的同时, 也带来了典型的 “小样本+高维特征” 问题, 使得模型面临过拟合风险。为此, 本文从两个层面开展降维与过拟合控制策略的设计:

5.4.1 降维技术的应用

为降低特征维度、剔除冗余特征, 提升模型训练效率, 本文引入两类降维策略: 第一类为特征选择法降维: 通过前文提到的 ANOVA F 检验、互信息、递归特征消除 (RFE) 和基于模型的重要性评分, 筛选出在多个方法中一致性较高的共识特征, 构成稳定的低维特征子集; 第二类为主成分分析 (PCA): 在特征间存在强相关性时, 采用 PCA 对原始高维特征进行线性组合降维, 保留 85% 以上累计方差贡献率的主成分, 有效压缩特征维度、缓解冗余, 其中根据不同模型得到的主成分如图 5.10 所示。

实验表明: 在维度降至原特征数的 30% 以内时, 分类准确率下降不超过 2%, 但训练速度提升超过 60%, 说明降维处理有效提升了模型效率且未显著损失判别能力。




图 5.10 PCA 特征贡献.

5.4.2 过拟合风险分析与控制措施

模型过拟合表现为：训练集准确率显著高于测试集，学习曲线之间存在较大偏差，且在新数据上泛化能力下降。为防止此问题，本文从以下几个方面进行了控制：（1）交叉验证（Cross-Validation）：采用 5 折交叉验证评估模型性能，确保训练过程不依赖特定样本划分，提升模型鲁棒性；（2）正则化控制（用于 SVM）：中通过调节惩罚系数 C 平衡间隔最大化与误差最小化；在 PCA 降维过程中通过控制主成分数，抑制噪声主导成分进入模型。（3）模型复杂度限制（用于随机森林）：限制最大树深度 max_depth ；设置每棵树的最小分裂样本数 min_samples_split ；控制使用的特征子集 max_features ；这些措施能够防止模型对训练集“死记硬背”，提升对新数据的泛化能力。（4）学习曲线监控：对训练集与验证集的学习曲线进行对比分析，及时调整参数以控制欠拟合或过拟合。（5）少量样本增强尝试：通过波形窗口滑动方式扩充训练样本数量，缓解模型在原始样本较少时的学习不充分问题。

实验验证结果：在加入降维与正则化处理后，模型的训练误差与验证误差趋于一致，F1 分数与 AUC 值均比未控制的原模型提高了 2%~3%；同时，训练时长明显缩短，说明降维与过拟合控制策略在本系统中取得了良好的平衡效果。



5.5 模型融合效果分析

在本研究中，分别构建了支持向量机（SVM）与随机森林（RF）分类模型，并基于它们进一步设计了融合判决模型以实现列车通信物理层健康状态的精确分类。从实验结果来看，SVM 模型在整体表现上优于 RF，其分类准确率达到了 91.67%，而 RF 模型准确率为 87.50%，在处理“线缆退化”等非线性特征占优状态上表现较好。为进一步提升模型的泛化能力与稳健性，本文将两模型输出结果进行集成，采用加权投票机制构建混合模型，最终实现了 93.75% 的分类准确率，显著优于单一模型。该结果表明，在面对特征重叠严重、噪声复杂的小样本场景下，融合多模型策略可以有效增强分类的稳定性与诊断精度，为物理层健康状态的智能识别提供了更加可靠的解决方案。

5.6 本章小结

本章围绕列车通信网络物理层的健康状态分类任务，系统地完成了分类模型的构建、参数优化与性能评估。首先，基于前期提取的多维特征，选取了支持向量机（SVM）与随机森林（RF）两种具有代表性的分类算法，分别从算法原理、适用场景与模型特性出发，分析其在本研究中的可行性。

在模型训练阶段，通过标准化处理、交叉验证与网格搜索等策略，针对小样本与高维特征环境，对 SVM 与 RF 模型分别进行了参数调优与训练优化。实验结果显示，SVM 模型准确率为 91.67%，整体性能优于 RF 模型（87.50%），但 RF 在处理非线性特征方面表现出更高的容错能力和运算效率。

为提升分类系统的整体性能与稳定性，本文进一步设计了融合判决模型，对 SVM 与 RF 的输出结果进行集成，构建加权投票融合策略。融合模型在各状态类别下均表现出更优的分类能力，其准确率提升至 93.75%，显著优于单一模型，验证了模型集成策略在小样本、多噪声环境下的鲁棒性与优势。

此外，为防止模型过拟合，本文结合特征选择与主成分分析（PCA）进行降维处理，并通过引入正则化与复杂度控制手段，增强了模型的泛化能力。最终，结合混淆矩阵与可视化分析，进一步验证了分类模型在不同健康状态下的判别能力和可解释性。

本章的研究为后续部署和应用提供了理论基础与实验支撑，也为构建高可靠性的物理层健康诊断系统提供了方法范式。



结 论

本研究围绕“基于机器学习的列车通信网络物理层健康状态诊断方法设计”这一课题，针对通信波形在不同状态（正常、环境干扰、通信故障、线缆退化）下的表现差异，提出了一套数据驱动、特征工程导向的智能诊断方法，完成了从数据采集、信号处理、特征构建、模型训练到结果评估的全过程系统设计。研究成果可为轨道交通系统的智能监测和故障预警提供理论基础与技术支持。

一、研究总结

数据处理与信号去噪方面：本文针对通信波形中存在的高频噪声与干扰脉冲问题，设计了基于小波阈值和中值滤波相结合的多尺度去噪方法，有效提升了信号的信噪比和特征可提取性；

特征提取与选择方面：构建了涵盖时域、频域、小波域的多维特征体系，并引入 ANOVA、互信息、递归特征消除（RFE）、PCA 等多种特征选择算法，最终构建出具备较高判别力的共识特征集；

分类建模与评估方面：分别构建了支持向量机（SVM）与随机森林（RF）模型，利用交叉验证与网格搜索进行参数优化。实验表明，两种模型在四分类任务中均表现出良好的分类性能，其中 RF 模型在准确率、训练效率和鲁棒性方面略占优势；

性能可视化与诊断验证方面：通过混淆矩阵、学习曲线、ROC 曲线等多维可视化手段，对模型诊断效果进行了解释与验证，进一步印证了所提出方法在实际通信系统状态识别中的适用性和可靠性。

二、方法优势与不足分析

优势：方法体系完整：涵盖采样数据预处理、特征工程、模型构建与评估的全过程，具有良好的工程可落地性；鲁棒性强：采用多种特征选择与分类器组合策略，显著提升了系统在多状态、小样本、高维特征条件下的适应能力；可扩展性高：特征结构与模型架构具有较强的可迁移性，可推广至其他通信系统或工业诊断任务。

不足：数据样本有限：采样数据总量较小，可能限制了模型在边界模糊状态下的进一步泛化能力；手工特征设计占主导：特征提取仍依赖人工领域知识，缺乏深层自动学习能力；模型部署尚未实现：分类模型尚未集成至实际系统中，未实现对列车运行状态的实时诊断响应。



三、后续工作展望

为进一步提升本研究成果的实用性与智能化水平，未来可从几个方面展开深入探索

(1) 引入迁移学习与深度神经网络结构：如卷积神经网络(CNN)、时序模型(LSTM)等，以实现自动化特征提取与更强的表征能力。(2) 数据增强与样本扩展：通过滑窗采样、噪声仿真等手段扩展训练集规模，提升模型在边界样本上的鲁棒性与准确性。(3) 嵌入式实时部署：将分类模型嵌入列车通信系统物理层终端，实现对信号状态的实时监测、自动预警与健康评估反馈。(4) 多模态数据融合：结合振动、电流、温度等其他传感数据，构建更全面的诊断体系，进一步提升识别精度与系统容错能力。



参考文献

- [1] 王欢欢,张涛.结合时域分析和改进双谱的通信信号特征提取算法[J].信号处理,2017,33(06):864-871.DOI:10.16798/j.issn.1003-0530.2017.06.012.
- [2] 徐玉龙,王金明,徐志军,等.基于小波熵的辐射源指纹特征提取方法[J].数据采集与处理,2014,29(04):631-635.DOI:10.16337/j.1004-9037.2014.04.009.
- [3] 袁晔,汤春阳,张博轩,等.融合时频特征的通信辐射源个体识别方法[J].电子测量技术,2025,48(01):129-136.DOI:10.19651/j.cnki.emt.2416650.
- [4] 靳福涛.基于信号分解与多尺度熵的滚动轴承支持向量机故障诊断方法[D].华东交通大学,2023.DOI:10.27147/d.cnki.ghdju.2023.000958.。
- [5] 彭璐.支持向量机分类算法研究与应用[D].湖南大学,2007.
- [6] Pedregosa, Fabian, Varoquaux, Gael, Gramfort, Alexandre, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.
- [7] CORTES, C, VAPNIK, V. SUPPORT-VECTOR NETWORKS[J]. MACHINE LEARNING, 1995, 20(03): 273-297. DOI: 10.1007/BF00994018..
- [8] 万广,陈忠辉,方洪波,等.基于特征融合的随机森林模型茶鲜叶分类[J].华南农业大学学报,2021,42(04):125-132.。
- [9] 郑和忠.基于支持向量机的地震波形分类方法的研究[D].青岛大学,2018.
- [10] 宋莉,孟庆建,张光玉,车琳琳,曹卫芳.基于波形特征和 SVM 的心电信号自动分类方法研究[J].中国医学物理学杂志,2010,27(4):2043-2046
- [11] 朱童.基于机器学习的采煤机健康状态评价与预测研究[D].安徽理工大学,2024.DOI:10.26918/d.cnki.ghngc.2024.001651.
- [12] 黎梓昕,林海军,徐雄,等.基于 KPCA-PSO-SVM 的水轮机组故障检测方法[J].排灌机械工程学报,2023,41(05):467-474.
- [13] 董红召,王乐恒,唐伟,等.融合时空特征的 PCA-PSO-SVM 臭氧(O₃)预测方法研究[J].中国环境科学,2021,41(02):596-605.DOI:10.19674/j.cnki.issn1000-6923.2021.0068.
- [14] 严欢,卢继平,覃俏云,等.基于多属性决策和支持向量机的风电功率非线性组合预测[J].电力系统自动化,2013,37(10):29-34.
- [15] 胡金昊.基于随机森林和 SVM 的软件缺陷预测方法研究[D].浙江工业大学,2020.DOI:10.27463/d.cnki.gzgyu.2020.000228.



致 谢

行文至此，百感交集。当为毕业论文画上最后一个句点时，四年的大学时光也即将落幕。从初入校园的懵懂青涩到如今的学有所成，这一路走来离不开诸多师长、同窗的指导与陪伴。在此，谨以最诚挚的笔墨，向所有给予我帮助的人致以衷心的感谢。

在这里首先要感谢我的导师杨军老师。杨军老师平日里工作繁多，但在我做毕业设计的每个阶段，从选题，研究思路，中期检查，后期详细设计，论文格式更改等整个过程中都给予了我悉心的指导。我的很多问题较为都很复杂烦琐，但是杨军老师仍然细心地帮我纠正了每一个错误。除了敬佩杨军老师的专业水平外，他的治学严谨和科学研究的、精神也是我永远学习的榜样，并将积极影响我今后的学习和工作。

感谢计算机科学与工程学院全体教师的辛勤培育。无论是专业基础课程的夯实，还是研究方法论的训练，各位老师以渊博的学识和创新的教学方式，为我搭建起系统的知识体系。尤其感谢在开题答辩和中期检查中提出宝贵意见的评审老师们，你们犀利的学术洞察力帮助我不断完善研究设计。

同窗情谊是求学路上最温暖的馈赠。感谢室友们营造的良好学习氛围，无数个挑灯夜战的晚上，我们互相鼓励、共同进步；感谢课题小组的伙伴们在资料收集、数据整理阶段的全力协助；特别致谢在论文修改阶段为我提供外文文献检索支持的学术伙伴，这份情谊我将永远铭记。

毕业论文既是本科学习的终点，更是新征程的起点。我将始终牢记“求真务实”“知行合一”的教诲，带着师长授予的知识火炬，在未来的道路上继续探索真知。

谨以此文献给所有关心、支持我成长的人。

学生签名：唐循宗

日 期：2025 年 5 月 18 日

